

E1.5. Desigualdade oráculo para o LASSO no desenho de produtos

wafc-draft, derivations/04-oraculo.tex

2026-09-19

Onde este resultado entra

Este arquivo junta as duas peças já fechadas e produz a cota não assintótica que E1.6 transforma em taxa. De E1.3 vem o *viés*: o erro de substituir f pela sua aproximação f_J em W_J (Corolário 1 abaixo é a citação do Corolário 1 daquele arquivo). De E1.4 vem a *condição de desenho*, na forma consumível que aquele arquivo entregou, a saber $\lambda_{\min}(\hat{\Sigma}) \geq \kappa_1 c_U/2$ com probabilidade alta, que por (2) domina qualquer constante de compatibilidade, *sem restrição de cone*. O que este arquivo acrescenta é o argumento do LASSO propriamente dito, com três desvios do molde de Bühlmann e van de Geer (2011, Seção 6.2):

- (a) os p níveis c_ℓ **não são penalizados** (D3). O tratamento usual põe as coordenadas não penalizadas dentro do suporte S e paga uma condição de cone; aqui elas são *perfiladas* (Lema 4), e o complemento de Schur transfere o autovalor de $\hat{\Sigma}$ ao bloco penalizado residualizado. É o que faz a hipótese de E1.4 bastar sem cone.
- (b) o modelo é **mal especificado dentro do espaço de aproximação**: $f \notin \text{span}$ das colunas de $\mathbf{Z}$, e o resíduo determinístico $\mathbf{b} = f - f_J$ entra como um segundo termo de ruído, tratado por Young em vez de por dualidade.
- (c) a **calibração** de λ é feita pelas normas empíricas das colunas, e não pelo máximo de $\mathbf{Z}$: a diferença é um fator $2^{J/2}$ na taxa (Lema 6 e Observação 2).

Diante de Klopp e Pensky (2015). A varredura de L2 (docs/busca-novidade.md, §1) registrou que para $q = 1$ e $\mathbf{X} \perp \mathbf{U}$ aquele trabalho já tem desigualdade oráculo não assintótica no mesmo desenho de produtos, com $\Sigma = \Omega \otimes \Phi$ (eq. 1.8) e concentração da Gram empírica restrita (Lema 1). O que aqui é novo, e é o que a posição do artigo tem de sustentar: aditividade em $q \geq 2$ moduladoras, com o termo cruzado entre U_m e $U_{m'}$ que não é produto de Kronecker; $\mathbf{X}$ dependente de $\mathbf{U}$; LASSO puro em vez de LASSO em blocos; e os níveis c_ℓ fora da penalidade, que em K&P entram nela. O preço desta última escolha aparece explicitamente no Teorema 1(iii), como o termo paramétrico $\sigma^2 p/n$, que K&P não têm.

1 Objetos

Modelo e amostra. $(Y_i, \mathbf{X}_i, \mathbf{U}_i)$, $i = 1, \dots, n$, são independentes e identicamente distribuídos, com

$$Y_i = f(\mathbf{X}_i, \mathbf{U}_i) + \varepsilon_i, \quad f(x, u) = \sum_{\ell=1}^p x_\ell \left\{ c_\ell + \sum_{m=1}^q g_{\ell m}(u_m) \right\},$$

na notação de docs/notacao.md (D1). Escrevemos $\mathbf{Y} = (Y_i)_i \in \mathbb{R}^n$, $\boldsymbol{\varepsilon} = (\varepsilon_i)_i$, $f = (f(\mathbf{X}_i, \mathbf{U}_i))_i$ e, para $a, h \in \mathbb{R}^n$, $\|a\|_n^2 = n^{-1} \sum_i a_i^2$ e $\langle a, h \rangle_n = n^{-1} \sum_i a_i h_i$.

Desenho, em dois blocos. Na ordem de colunas de D12, a matriz $\mathbf{Z} \in \mathbb{R}^{n \times (p+d)}$, $d = pqN_J$, parte em

$$\mathbf{Z} = [\mathbf{A} \ \mathbf{B}], \quad \mathbf{A}_{i\ell} = X_{i\ell}, \quad \mathbf{B}_{i,(\ell m, jk)} = X_{i\ell} \psi_{jk}(U_{im}),$$

o bloco $\mathbf{A} \in \mathbb{R}^{n \times p}$ dos p termos não penalizados e o bloco $\mathbf{B} \in \mathbb{R}^{n \times d}$ dos produtos. Escrevemos $\hat{\Sigma} = \mathbf{Z}^\top \mathbf{Z}/n$ e, para o parâmetro, $\beta = (\mathbf{c}, \boldsymbol{\theta}) \in \mathbb{R}^p \times \mathbb{R}^d$.

Estimador. Com $\lambda > 0$,

$$\hat{\beta} = (\hat{\mathbf{c}}, \hat{\boldsymbol{\theta}}) \in \arg \min_{(\mathbf{c}, \boldsymbol{\theta}) \in \mathbb{R}^p \times \mathbb{R}^d} \left\{ \|\mathbf{Y} - \mathbf{A}\mathbf{c} - \mathbf{B}\boldsymbol{\theta}\|_n^2 + 2\lambda \|\boldsymbol{\theta}\|_1 \right\}, \quad (1)$$

e $\hat{f} = \mathbf{A}\hat{\mathbf{c}} + \mathbf{B}\hat{\boldsymbol{\theta}}$ é o ajuste. A penalidade não toca $\mathbf{c}$: é D3.

Oráculo e viés. $\beta^* = (\mathbf{c}, \boldsymbol{\theta}^*)$ é o vetor de E1.3, com $\theta_{\ell m, jk}^* = \langle g_{\ell m}, \psi_{jk} \rangle$ para $j < J$, de modo que $f_J = \mathbf{Z}\beta^*$ é a aproximação em W_J . O resíduo determinístico é

$$\mathbf{b} = f - f_J \in \mathbb{R}^n, \quad \|\mathbf{b}\|_n^2 = \frac{1}{n} \sum_i (f - f_J)^2(\mathbf{X}_i, \mathbf{U}_i).$$

Escrevemos $S_0 = \text{supp}(\boldsymbol{\theta}^*)$ e $s_0 = |S_0|$. Note que s_0 é a esparsidade *do oráculo do espaço de aproximação*, não uma hipótese sobre o modelo: sob a Hipótese de Besov de E1.3 os $\theta_{\ell m, jk}^*$ decaem mas não se anulam, e em geral $s_0 = d$. É por isso que a taxa lenta do Teorema 1(i), que não menciona s_0 , é o enunciado incondicional, e a taxa rápida de (ii) é útil quando $\boldsymbol{\theta}^*$ é comprimível; a distinção é a mesma que o WALL faz entre o Teorema 1 e o Corolário de compressibilidade, e é matéria de E1.6.

Perfilagem. $\Pi_{\mathbf{A}} = \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top$ é a projeção ortogonal sobre o espaço-coluna de $\mathbf{A}$ (definida quando $\mathbf{A}$ tem posto p) e $M_{\mathbf{A}} = I_n - \Pi_{\mathbf{A}}$. Os objetos residualizados são

$$\tilde{\mathbf{B}} = M_{\mathbf{A}} \mathbf{B}, \quad \tilde{\mathbf{Y}} = M_{\mathbf{A}} \mathbf{Y}, \quad \hat{\Sigma}_{\mathbf{B}|\mathbf{A}} = \tilde{\mathbf{B}}^\top \tilde{\mathbf{B}}/n \in \mathbb{R}^{d \times d}, \quad \tilde{\gamma} = \lambda_{\min}(\hat{\Sigma}_{\mathbf{B}|\mathbf{A}}).$$

Finalmente, a maior norma empírica de coluna penalizada,

$$\hat{\sigma}_{\max}^2 = \max_a \frac{1}{n} \sum_{i=1}^n \mathbf{B}_{ia}^2 = \max_a (\hat{\Sigma})_{aa}, \quad a \text{ percorrendo as } d \text{ colunas penalizadas},$$

que é mensurável em $(\mathbf{X}, \mathbf{U})$. É esta a quantidade que o plano chama $\|\mathbf{Z}\|_{\max}$ (Observação 2).

2 Hipóteses

Além das hipóteses de E1.3 (base, regularidade de Besov, densidade das moduladoras, $\mathbf{X}$ limitada) e de E1.4 (moduladoras, covariáveis lineares, base de wavelets), que são citadas onde entram, este arquivo usa duas.

Hipótese 1 (amostra). $(Y_i, \mathbf{X}_i, \mathbf{U}_i)_{i \leq n}$ são i.i.d. e seguem o modelo acima.

Hipótese 2 (erro sub-gaussiano). Existe $\sigma < \infty$ tal que, quase certamente,

$$\mathbb{E}[e^{t\varepsilon_i} \mid \mathbf{X}_i, \mathbf{U}_i] \leq e^{\sigma^2 t^2/2} \quad \text{para todo } t \in \mathbb{R}.$$

Em particular $\mathbb{E}[\varepsilon_i \mid \mathbf{X}_i, \mathbf{U}_i] = 0$ e $\text{Var}(\varepsilon_i \mid \mathbf{X}_i, \mathbf{U}_i) \leq \sigma^2$. O erro gaussiano homocedástico é o caso $\sigma^2 = \text{Var}(\varepsilon)$.

Duas peças já provadas são usadas na forma em que foram deixadas. Elas não consomem números novos: os contadores abaixo são recuados para que apareçam com o número global que já têm (Corolário 1 de E1.3, Proposição 3 de E1.4).

Corolário 1 (viés de aproximação; provado em E1.3). *Sob as hipóteses de E1.3,*

$$\|f - f_J\|_{L_2(P)}^2 \leq \frac{(pq)^2 C_X^2 C_U C_g^2}{1 - 2^{-2s'}} 2^{-2Js'} =: \mathcal{B}_J^2,$$

e, se $s > 1/\pi$, $\|\mathbf{b}\|_n \leq \|f - f_J\|_\infty \leq pq C_X (L - 1) \|\psi\|_\infty C_g 2^{-J(s-1/\pi)} / (1 - 2^{-(s-1/\pi)})$ para qualquer amostra.

Proposição 3 (Gram empírica; provada em E1.4, parte (iv)). *Sob as hipóteses de E1.4, com $\gamma = \kappa_1 c_U$ e $D = p + d$,*

$$P(\lambda_{\min}(\widehat{\Sigma}) \geq \gamma/2) \geq 1 - 2D \exp\left(-\frac{n\gamma^2}{8R_J(\kappa_2 C_U + \gamma/3)}\right), \quad R_J = pB_X^2(1 + qC_\psi 2^J),$$

probabilidade que tende a 1 quando $pq2^J \log(pq2^J)/n \rightarrow 0$. Além disso, para toda matriz simétrica A e todo suporte S ,

$$\phi_0^2(S; A) \geq \lambda_{\min}(A). \quad (2)$$

3 Os quatro lemas

Lema 4 (perfilagem dos níveis e complemento de Schur). *Suponha que $\mathbf{A}$ tenha posto p . Então:*

$$(i) \quad \widehat{\boldsymbol{\theta}} \text{ minimiza } \left\| \widetilde{\mathbf{Y}} - \widetilde{\mathbf{B}}\widehat{\boldsymbol{\theta}} \right\|_n^2 + 2\lambda \|\widehat{\boldsymbol{\theta}}\|_1 \text{ e } \widehat{\mathbf{c}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top (\mathbf{Y} - \mathbf{B}\widehat{\boldsymbol{\theta}});$$

$$(ii) \quad \text{com } v = \widehat{\boldsymbol{\theta}} - \boldsymbol{\theta}^*,$$

$$\widehat{f} - f_J = \widetilde{\mathbf{B}}v + \Pi_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon}); \quad (3)$$

$$(iii) \quad \widehat{\Sigma}_{\mathbf{B}|\mathbf{A}} = \widehat{\Sigma}_{\mathbf{B}\mathbf{B}} - \widehat{\Sigma}_{\mathbf{B}\mathbf{A}} \widehat{\Sigma}_{\mathbf{A}\mathbf{A}}^{-1} \widehat{\Sigma}_{\mathbf{A}\mathbf{B}} \text{ e}$$

$$\widetilde{\gamma} = \lambda_{\min}(\widehat{\Sigma}_{\mathbf{B}|\mathbf{A}}) \geq \lambda_{\min}(\widehat{\Sigma}); \quad (4)$$

(iv) se $\lambda_{\min}(\widehat{\Sigma}) > 0$, o minimizador em (1) é único.

Lema 5 (calibração de λ). *Sob as Hipóteses 1 e 2, para todo $\alpha \in (0, 1)$,*

$$P\left(\|\widetilde{\mathbf{B}}^\top \boldsymbol{\varepsilon}/n\|_\infty > \lambda_0\right) \leq \alpha, \quad \lambda_0 = \sigma \widehat{\sigma}_{\max} \sqrt{\frac{2 \log(2d/\alpha)}{n}}.$$

Lema 6 (normas empíricas das colunas). *Sob as hipóteses de E1.3 e E1.4 ($\max_\ell |X_\ell| \leq B_X$ q.c., densidade marginal de cada U_m limitada por C_U , wavelets periodizadas de uma família de suporte compacto), para toda coluna penalizada a vale $E[(\widehat{\Sigma})_{aa}] \leq B_X^2 C_U$ e, para todo $t > 0$,*

$$P(\widehat{\sigma}_{\max}^2 > B_X^2 C_U + t) \leq d \exp\left(-\frac{nt^2}{2(R'_J B_X^2 C_U + R'_J t/3)}\right), \quad R'_J = B_X^2 \|\psi\|_\infty^2 2^{J-1}.$$

Em particular $P(\widehat{\sigma}_{\max}^2 \leq 2B_X^2 C_U) \rightarrow 1$ sempre que $2^J \log d/n \rightarrow 0$.

Lema 7 (norma ℓ_1 do oráculo em Besov). *Sob a Hipótese de regularidade de Besov de E1.3, para todo (ℓ, m) e todo $j \geq 0$,*

$$\sum_k |\theta_{\ell m, jk}^*| \leq 2^{j(1-1/\pi)} \|\theta_{\ell m, j}^*\|_\pi \leq C_g 2^{j(1/2-s)},$$

sem dependência de π , e portanto

$$\|\boldsymbol{\theta}^*\|_1 \leq pq C_g \sum_{j=0}^{J-1} 2^{j(1/2-s)} \asymp pq C_g \times \begin{cases} (1 - 2^{-(s-1/2)})^{-1}, & s > 1/2, \\ J, & s = 1/2, \\ (2^{1/2-s} - 1)^{-1} 2^{J(1/2-s)}, & s < 1/2. \end{cases}$$

4 O teorema

Teorema 1 (desigualdade oráculo). *Sob as Hipóteses 1 e 2, suponha $\mathbf{A}$ de posto p e $\lambda \geq 2\lambda_0$ com λ_0 do Lema 5. Seja $\mathcal{T} = \{\|\tilde{\mathbf{B}}^\top \boldsymbol{\varepsilon}/n\|_\infty \leq \lambda/2\}$, evento de probabilidade pelo menos $1 - \alpha$. Em $\mathcal{T}$, com $v = \hat{\boldsymbol{\theta}} - \boldsymbol{\theta}^*$:*

(i) (Taxa lenta; nenhuma condição de desenho.)

$$\frac{1}{2} \left\| \tilde{\mathbf{B}}v \right\|_n^2 + \lambda \left\| \hat{\boldsymbol{\theta}} \right\|_1 \leq 3\lambda \|\boldsymbol{\theta}^*\|_1 + 2\|\mathbf{b}\|_n^2, \quad \text{em particular} \quad \left\| \tilde{\mathbf{B}}v \right\|_n^2 \leq 6\lambda \|\boldsymbol{\theta}^*\|_1 + 4\|\mathbf{b}\|_n^2.$$

(ii) (Taxa rápida.) Se $\tilde{\gamma} > 0$,

$$\left\| \tilde{\mathbf{B}}v \right\|_n^2 \leq \frac{64\lambda^2 s_0}{\tilde{\gamma}} + 16\|\mathbf{b}\|_n^2, \quad \|v\|_1 \leq \frac{40\lambda s_0}{\tilde{\gamma}} + \frac{10\|\mathbf{b}\|_n^2}{\lambda}, \quad \|v\|_2^2 \leq \frac{64\lambda^2 s_0}{\tilde{\gamma}^2} + \frac{16\|\mathbf{b}\|_n^2}{\tilde{\gamma}}.$$

(iii) (Erro de predição.) Em qualquer dos dois regimes,

$$\left\| \hat{f} - f \right\|_n \leq \left\| \tilde{\mathbf{B}}v \right\|_n + 2\|\mathbf{b}\|_n + \|\Pi_{\mathbf{A}}\boldsymbol{\varepsilon}\|_n, \quad \left\| \hat{f} - f \right\|_n^2 \leq 3(\left\| \tilde{\mathbf{B}}v \right\|_n^2 + 4\|\mathbf{b}\|_n^2 + \|\Pi_{\mathbf{A}}\boldsymbol{\varepsilon}\|_n^2),$$

e $\mathbb{E}[\|\Pi_{\mathbf{A}}\boldsymbol{\varepsilon}\|_n^2 \mid \mathbf{X}, \mathbf{U}] \leq \sigma^2 p/n$, de modo que $\mathbb{P}(\|\Pi_{\mathbf{A}}\boldsymbol{\varepsilon}\|_n^2 > \sigma^2 p/(n\alpha')) \leq \alpha'$ para todo $\alpha' \in (0, 1)$.

Corolário 2 (as duas taxas, com E1.3 e E1.4 instanciados). *Acrescente as hipóteses de E1.3 e E1.4 e suponha $2^J \log d/n \rightarrow 0$ — o que não é hipótese nova, pois é implicado pela condição $pq2^J \log(pq2^J)/n \rightarrow 0$ que a Proposição 3 já exige, com $d = pqN_J \asymp pq2^J$. Tome*

$$\lambda = 2\sigma B_X \sqrt{2C_U} \sqrt{\frac{2\log(2d/\alpha)}{n}}, \quad d = pqN_J.$$

Então, com probabilidade que tende a 1 menos $\alpha + \alpha' + \alpha''$,

$$\left\| \hat{f} - f \right\|_n^2 \lesssim \underbrace{\frac{\sigma^2 B_X^2 C_U}{\kappa_1 C_U} \frac{s_0 \log(pqN_J)}{n}}_{\text{estimação}} + \underbrace{\frac{\mathcal{B}_J^2}{\alpha'}}_{\text{viés}} + \underbrace{\frac{\sigma^2 p}{n\alpha''}}_{\text{níveis}}, \quad \mathcal{B}_J^2 \asymp (pq)^2 C_X^2 C_U C_g^2 2^{-2Js'},$$

e, sem nenhuma condição de desenho, a versão lenta com $\lambda \|\boldsymbol{\theta}^*\|_1$ no lugar do termo de estimação, com $\|\boldsymbol{\theta}^*\|_1$ dado pelo Lema 7.

Corolário 3 (o que E1.6 consome). *Nas condições do Teorema 1(ii), como as $\{\psi_{jk}\}_{j < J}$ são ortonormais em $L_2[0, 1]$,*

$$\sum_{\ell, m} \left\| \hat{g}_{\ell m} - \Pi_J g_{\ell m} \right\|_{L_2[0, 1]}^2 = \|v\|_2^2 \leq \frac{64\lambda^2 s_0}{\tilde{\gamma}^2} + \frac{16\|\mathbf{b}\|_n^2}{\tilde{\gamma}},$$

com $\hat{g}_{\ell m} = \sum_{j < J, k} \theta_{\ell m, jk} \psi_{jk}$, e portanto, pelo Lema 1 de E1.3 e a desigualdade triangular,

$$\sum_{\ell, m} \left\| \hat{g}_{\ell m} - g_{\ell m} \right\|_{L_2[0, 1]}^2 \leq 2\|v\|_2^2 + \frac{2pq C_g^2}{1 - 2^{-2s'}} 2^{-2Js'}.$$

Observação 1 (por que não há cone). O tratamento usual de coordenadas não penalizadas (Bühlmann e van de Geer, 2011, Seção 6.9, pp. 139–141, onde os pesos da LASSO ponderada são $w_1 = \dots = w_r = 0$) as coloca dentro do suporte S e exige a compatibilidade $\phi_0^2(S; \hat{\Sigma})$ no cone $\|\delta_{S^c}\|_1 \leq 3\|\delta_S\|_1$. Aqui a perfilagem do Lema 4 as remove do problema, e (4) transfere

o autovalor cheio de $\widehat{\Sigma}$ ao bloco residualizado: $\widetilde{\gamma} \geq \lambda_{\min}(\widehat{\Sigma}) \geq \gamma/2$ pela Proposição 3. Nada de cone, nada de ϕ_0^2 , e a constante é a mesma para todo S_0 . Isso só é possível porque E1.4 entregou o autovalor mínimo cheio, e não a compatibilidade restrita (D13); com a versão restrita da Observação 1 daquele arquivo (o regime $pq \gg n^{1/2}$), o cone volta, e com uma diferença a registrar: o passo do Teorema 1(ii), Caso 1, produz $\|v_{S_0^c}\|_1 \leq 4\|v_{S_0}\|_1$, e não 3, porque o viés consome parte da folga. A constante 3 da definição de ϕ_0^2 em E1.4 teria de virar 4 nesse regime.

Observação 2 (a calibração é pelas colunas, não pelo máximo). O plano escreve $\lambda \asymp \sigma \|\mathbf{Z}\|_{\max} \sqrt{\log(pqN_J)/n}$. A leitura correta de $\|\mathbf{Z}\|_{\max}$ é a norma empírica máxima de coluna, $\widehat{\sigma}_{\max}$, que é a normalização que Bühlmann e van de Geer supõem ($(\widehat{\Sigma})_{aa} = 1$) e a que o Lema 5 usa; pelo Lema 6 ela é $O_p(1)$. A leitura literal, $\max_{i,a} |Z_{ia}|$, seria da ordem $B_X \|\psi\|_{\infty} 2^{(J-1)/2}$ e inflaria λ por $2^{J/2}$, destruindo a taxa de E1.6. A conferência numérica separa as duas: em $J = 2, \dots, 6$ com $n = 4000$, $\widehat{\sigma}_{\max}$ vai de 1.02 a 1.14 enquanto $\max_{i,a} |Z_{ia}|$ vai de 3.04 a 11.47, o fator $2^{J/2}$ previsto. É o mesmo ponto que o WALL faz ao observar que a calibração sub-gaussiana $\lambda_n \asymp \sqrt{J_n/n}$ não sofre inflação logarítmica (Lemma “LASSO prediction consistency”, Passo 3a).

Observação 3 (o termo $\sigma^2 p/n$). É o preço de não penalizar os p níveis: um projeto de dimensão p ajustado por mínimos quadrados custa $\sigma^2 p/n$ em predição, e nenhuma escolha de λ o remove. Ele é dominado pelo termo de estimação sempre que $p \lesssim s_0 \log(pqN_J)$, o que vale em todos os regimes de E1.6 (p fixo). A cota de Markov usada no Teorema 1(iii) é exata em média: a conferência acha $E \|\Pi_{\mathbf{A}} \boldsymbol{\varepsilon}\|_n^2 / (\sigma^2 p/n)$ entre 0.90 e 1.19.

5 Provas

Lema 4

(i). O objetivo de (1) é convexo e, para $\boldsymbol{\theta}$ fixo, quadrático e coercivo em $\mathbf{c}$ (posto p), com mínimo em $\mathbf{c} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top (\mathbf{Y} - \mathbf{B}\boldsymbol{\theta})$ e valor $\|M_{\mathbf{A}}(\mathbf{Y} - \mathbf{B}\boldsymbol{\theta})\|_n^2 = \|\widetilde{\mathbf{Y}} - \widetilde{\mathbf{B}}\boldsymbol{\theta}\|_n^2$, pois $M_{\mathbf{A}}$ é idempotente e simétrico. Minimizar primeiro em $\mathbf{c}$ e depois em $\boldsymbol{\theta}$ dá o mesmo conjunto de minimizadores que minimizar conjuntamente.

(ii). Como $\mathbf{A}\widehat{\mathbf{c}} = \Pi_{\mathbf{A}}(\mathbf{Y} - \mathbf{B}\widehat{\boldsymbol{\theta}})$ e $\mathbf{A}\mathbf{c} = \Pi_{\mathbf{A}}\mathbf{A}\mathbf{c}$, e $\mathbf{Y} = \mathbf{A}\mathbf{c} + \mathbf{B}\boldsymbol{\theta}^* + \mathbf{b} + \boldsymbol{\varepsilon}$,

$$\mathbf{A}(\widehat{\mathbf{c}} - \mathbf{c}) = \Pi_{\mathbf{A}}(\mathbf{B}\boldsymbol{\theta}^* + \mathbf{b} + \boldsymbol{\varepsilon} - \mathbf{B}\widehat{\boldsymbol{\theta}}) = \Pi_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon}) - \Pi_{\mathbf{A}}\mathbf{B}v,$$

logo $\widehat{f} - f_J = \mathbf{A}(\widehat{\mathbf{c}} - \mathbf{c}) + \mathbf{B}v = M_{\mathbf{A}}\mathbf{B}v + \Pi_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon}) = \widetilde{\mathbf{B}}v + \Pi_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon})$.

(iii). A identidade é $\widetilde{\mathbf{B}}^\top \widetilde{\mathbf{B}}/n = (\mathbf{B}^\top \mathbf{B} - \mathbf{B}^\top \mathbf{A}(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{B})/n$, onde os fatores n se cancelam. Para a desigualdade, a caracterização variacional do complemento de Schur dá, para todo $v \in \mathbb{R}^d$,

$$v^\top \widehat{\Sigma}_{\mathbf{B}|\mathbf{A}} v = \min_{u \in \mathbb{R}^p} \begin{pmatrix} u \\ v \end{pmatrix}^\top \widehat{\Sigma} \begin{pmatrix} u \\ v \end{pmatrix} \geq \min_{u \in \mathbb{R}^p} \lambda_{\min}(\widehat{\Sigma}) (\|u\|_2^2 + \|v\|_2^2) = \lambda_{\min}(\widehat{\Sigma}) \|v\|_2^2,$$

o mínimo sendo atingido em $u = -\widehat{\Sigma}_{\mathbf{A}\mathbf{A}}^{-1} \widehat{\Sigma}_{\mathbf{A}\mathbf{B}} v$.

(iv). $\lambda_{\min}(\widehat{\Sigma}) > 0$ torna $\boldsymbol{\beta} \mapsto \|\mathbf{Y} - \mathbf{Z}\boldsymbol{\beta}\|_n^2$ estritamente convexa; somar uma função convexa preserva a estrita convexidade. $\square$

Lema 5

Condicione em $(\mathbf{X}, \mathbf{U}) = ((\mathbf{X}_i, \mathbf{U}_i)_i)$. Nessa condicional $\widetilde{\mathbf{B}}$ e $\widehat{\sigma}_{\max}$ são constantes e os ε_i são independentes e sub-gaussianos de parâmetro σ (Hipótese 2 e a independência da amostra).

Para a coluna a , $(\tilde{\mathbf{B}}^\top \boldsymbol{\varepsilon})_a/n = n^{-1} \sum_i \tilde{\mathbf{B}}_{ia} \varepsilon_i$ é sub-gaussiana de parâmetro $\sigma \|\tilde{\mathbf{B}}^{(a)}\|_2/n$, de modo que

$$\mathbb{P}\left(|(\tilde{\mathbf{B}}^\top \boldsymbol{\varepsilon})_a/n| > t \mid \mathbf{X}, \mathbf{U}\right) \leq 2 \exp\left(-\frac{n^2 t^2}{2\sigma^2 \|\tilde{\mathbf{B}}^{(a)}\|_2^2}\right).$$

Como $M_{\mathbf{A}}$ é uma projeção ortogonal, $\|\tilde{\mathbf{B}}^{(a)}\|_2 = \|M_{\mathbf{A}} \mathbf{B}^{(a)}\|_2 \leq \|\mathbf{B}^{(a)}\|_2 = \sqrt{n} (\hat{\Sigma})_{aa}^{1/2} \leq \sqrt{n} \hat{\sigma}_{\max}$. Com $t = \lambda_0 = \sigma \hat{\sigma}_{\max} \sqrt{2 \log(2d/\alpha)/n}$ o expoente é no máximo $-\log(2d/\alpha)$, e cada coordenada tem probabilidade no máximo α/d . A união sobre as d colunas e a torre fecham. $\square$

Lema 6

Para a coluna $a = (\ell m, jk)$, o somando é $W_i = X_{i\ell}^2 \psi_{jk}(U_{im})^2 \geq 0$. A média: $\mathbb{E}[W] \leq B_X^2 \mathbb{E}[\psi_{jk}(U_m)^2] = B_X^2 \int_0^1 \psi_{jk}^2 p_{U_m} \leq B_X^2 C_U$, pela ortonormalidade e pela densidade marginal limitada (Hipótese de densidade de E1.3). O alcance: $\|\psi_{jk}\|_\infty = 2^{j/2} \|\psi\|_\infty$ e $j \leq J-1$, logo $0 \leq W_i \leq B_X^2 \|\psi\|_\infty^2 2^{J-1} = R'_J$. A variância: $\text{Var}(W) \leq \mathbb{E}[W^2] \leq R'_J \mathbb{E}[W] \leq R'_J B_X^2 C_U$. A desigualdade de Bernstein unilateral e a união sobre as d colunas dão o enunciado. Com $t = B_X^2 C_U$ o expoente é $-3n B_X^2 C_U / (8R'_J)$, e $R'_J \asymp 2^J$, de modo que $d \exp(-cn/2^J) \rightarrow 0$ sempre que $2^J \log d/n \rightarrow 0$. $\square$

Lema 7

Em $\mathbb{R}^{2^j}$ e para $1 \leq \pi \leq \infty$, Hölder dá $\|a\|_1 \leq (2^j)^{1-1/\pi} \|a\|_\pi$ (com $1/\infty = 0$). Com a Hipótese de Besov, $\left\|\theta_{\ell m, j}^*\right\|_\pi \leq C_g 2^{-j(s+1/2-1/\pi)}$, e o expoente resultante é $j(1-1/\pi) - j(s+1/2-1/\pi) = j(1/2-s)$: o π desaparece. Somar sobre $j < J$ e sobre os pq blocos dá a segunda afirmação, com a soma geométrica nos três regimes. $\square$

Teorema 1

Passo 1 (desigualdade básica). Pelo Lema 4(i), $\hat{\boldsymbol{\theta}}$ minimiza $\left\|\tilde{\mathbf{Y}} - \tilde{\mathbf{B}}\hat{\boldsymbol{\theta}}\right\|_n^2 + 2\lambda \|\hat{\boldsymbol{\theta}}\|_1$; comparando com $\boldsymbol{\theta}^*$,

$$\left\|\tilde{\mathbf{Y}} - \tilde{\mathbf{B}}\hat{\boldsymbol{\theta}}\right\|_n^2 + 2\lambda \|\hat{\boldsymbol{\theta}}\|_1 \leq \left\|\tilde{\mathbf{Y}} - \tilde{\mathbf{B}}\boldsymbol{\theta}^*\right\|_n^2 + 2\lambda \|\boldsymbol{\theta}^*\|_1.$$

Como $\mathbf{Y} = \mathbf{A}\mathbf{c} + \mathbf{B}\boldsymbol{\theta}^* + \mathbf{b} + \boldsymbol{\varepsilon}$ e $M_{\mathbf{A}}\mathbf{A} = 0$, vale $\tilde{\mathbf{Y}} = \tilde{\mathbf{B}}\boldsymbol{\theta}^* + M_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon})$; escrevendo $r = M_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon})$ e $v = \hat{\boldsymbol{\theta}} - \boldsymbol{\theta}^*$, tem-se $\tilde{\mathbf{Y}} - \tilde{\mathbf{B}}\hat{\boldsymbol{\theta}} = r - \tilde{\mathbf{B}}v$ e $\tilde{\mathbf{Y}} - \tilde{\mathbf{B}}\boldsymbol{\theta}^* = r$, donde

$$\left\|\tilde{\mathbf{B}}v\right\|_n^2 + 2\lambda \|\hat{\boldsymbol{\theta}}\|_1 \leq 2\langle r, \tilde{\mathbf{B}}v \rangle_n + 2\lambda \|\boldsymbol{\theta}^*\|_1. \quad (5)$$

Passo 2 (os dois ruídos). Como $M_{\mathbf{A}}\tilde{\mathbf{B}} = \tilde{\mathbf{B}}$ e $M_{\mathbf{A}}$ é simétrica, $\langle r, \tilde{\mathbf{B}}v \rangle_n = \langle \mathbf{b} + \boldsymbol{\varepsilon}, \tilde{\mathbf{B}}v \rangle_n$. O termo estocástico é tratado por dualidade: em $\mathcal{T}$,

$$2|\langle \boldsymbol{\varepsilon}, \tilde{\mathbf{B}}v \rangle_n| \leq 2\|\tilde{\mathbf{B}}^\top \boldsymbol{\varepsilon}/n\|_\infty \|v\|_1 \leq \lambda \|v\|_1.$$

O termo determinístico é tratado por Cauchy–Schwarz e Young, e não por dualidade, porque $\mathbf{b}$ não é pequeno em ℓ_∞ coordenada a coordenada:

$$2|\langle \mathbf{b}, \tilde{\mathbf{B}}v \rangle_n| = 2|\langle M_{\mathbf{A}}\mathbf{b}, \tilde{\mathbf{B}}v \rangle_n| \leq 2\|M_{\mathbf{A}}\mathbf{b}\|_n \left\|\tilde{\mathbf{B}}v\right\|_n \leq 2\|\mathbf{b}\|_n \left\|\tilde{\mathbf{B}}v\right\|_n \leq \frac{1}{2} \left\|\tilde{\mathbf{B}}v\right\|_n^2 + 2\|\mathbf{b}\|_n^2.$$

Levando as duas a (5),

$$\frac{1}{2} \left\|\tilde{\mathbf{B}}v\right\|_n^2 + 2\lambda \|\hat{\boldsymbol{\theta}}\|_1 \leq \lambda \|v\|_1 + 2\lambda \|\boldsymbol{\theta}^*\|_1 + 2\|\mathbf{b}\|_n^2. \quad (6)$$

Passo 3 (taxa lenta). $\|v\|_1 \leq \|\widehat{\boldsymbol{\theta}}\|_1 + \|\boldsymbol{\theta}^*\|_1$ em (6) dá (i) diretamente. Nenhuma propriedade de $\widehat{\Sigma}$ foi usada.

Passo 4 (cone). Como $\boldsymbol{\theta}_{S_0^c}^* = 0$, $\|\widehat{\boldsymbol{\theta}}\|_1 = \|\widehat{\boldsymbol{\theta}}_{S_0}\|_1 + \|v_{S_0^c}\|_1 \geq \|\boldsymbol{\theta}^*\|_1 - \|v_{S_0}\|_1 + \|v_{S_0^c}\|_1$, e $\|v\|_1 = \|v_{S_0}\|_1 + \|v_{S_0^c}\|_1$. Substituindo em (6) e cancelando $2\lambda\|\boldsymbol{\theta}^*\|_1$,

$$\frac{1}{2} \|\widetilde{\mathbf{B}}v\|_n^2 + \lambda\|v_{S_0^c}\|_1 \leq 3\lambda\|v_{S_0}\|_1 + 2\|\mathbf{b}\|_n^2. \quad (7)$$

Passo 5 (os dois casos). **Caso 1:** $2\|\mathbf{b}\|_n^2 \leq \lambda\|v_{S_0}\|_1$. Então (7) dá $\frac{1}{2} \|\widetilde{\mathbf{B}}v\|_n^2 + \lambda\|v_{S_0^c}\|_1 \leq 4\lambda\|v_{S_0}\|_1$. Por Cauchy–Schwarz e (4), $\|v_{S_0}\|_1 \leq \sqrt{s_0}\|v\|_2 \leq \sqrt{s_0} \|\widetilde{\mathbf{B}}v\|_n / \sqrt{\gamma}$, logo

$$\frac{1}{2} \|\widetilde{\mathbf{B}}v\|_n^2 \leq 4\lambda\sqrt{s_0} \|\widetilde{\mathbf{B}}v\|_n / \sqrt{\gamma} \implies \|\widetilde{\mathbf{B}}v\|_n \leq 8\lambda\sqrt{s_0/\gamma} \implies \|\widetilde{\mathbf{B}}v\|_n^2 \leq 64\lambda^2 s_0 / \gamma.$$

Do mesmo display, $\|v_{S_0^c}\|_1 \leq 4\|v_{S_0}\|_1$, donde $\|v\|_1 \leq 5\|v_{S_0}\|_1 \leq 5\sqrt{s_0} \|\widetilde{\mathbf{B}}v\|_n / \sqrt{\gamma} \leq 40\lambda s_0 / \gamma$; e $\|v\|_2^2 \leq \|\widetilde{\mathbf{B}}v\|_n^2 / \gamma \leq 64\lambda^2 s_0 / \gamma^2$.

Caso 2: $2\|\mathbf{b}\|_n^2 > \lambda\|v_{S_0}\|_1$. Então (7) dá $\frac{1}{2} \|\widetilde{\mathbf{B}}v\|_n^2 \leq 3\lambda\|v_{S_0}\|_1 + 2\|\mathbf{b}\|_n^2 < 8\|\mathbf{b}\|_n^2$, isto é $\|\widetilde{\mathbf{B}}v\|_n^2 < 16\|\mathbf{b}\|_n^2$; também $\lambda\|v_{S_0^c}\|_1 < 8\|\mathbf{b}\|_n^2$ e $\lambda\|v_{S_0}\|_1 < 2\|\mathbf{b}\|_n^2$, donde $\|v\|_1 < 10\|\mathbf{b}\|_n^2 / \lambda$; e $\|v\|_2^2 \leq \|\widetilde{\mathbf{B}}v\|_n^2 / \gamma < 16\|\mathbf{b}\|_n^2 / \gamma$. Como cada quantidade é majorada pelo máximo dos dois casos, e o máximo pela soma, sai (ii).

Passo 6 (erro de predição). Por (3), $\widehat{f} - f = \widetilde{\mathbf{B}}v + \Pi_{\mathbf{A}}(\mathbf{b} + \boldsymbol{\varepsilon}) - \mathbf{b}$, e como $\Pi_{\mathbf{A}}$ é uma projeção, $\|\Pi_{\mathbf{A}}\mathbf{b}\|_n \leq \|\mathbf{b}\|_n$; a desigualdade triangular dá a primeira parte de (iii), e $(x+y+z)^2 \leq 3(x^2+y^2+z^2)$ a segunda. Para a última, condicionalmente em $(\mathbf{X}, \mathbf{U})$ os ε_i são independentes, centrados e de variância no máximo σ^2 , logo

$$\mathbb{E}[\|\Pi_{\mathbf{A}}\boldsymbol{\varepsilon}\|_n^2 \mid \mathbf{X}, \mathbf{U}] = \frac{1}{n} \text{tr}(\Pi_{\mathbf{A}} \text{Cov}(\boldsymbol{\varepsilon} \mid \mathbf{X}, \mathbf{U})) = \frac{1}{n} \sum_i (\Pi_{\mathbf{A}})_{ii} \text{Var}(\varepsilon_i \mid \mathbf{X}, \mathbf{U}) \leq \frac{\sigma^2}{n} \text{tr}(\Pi_{\mathbf{A}}) \leq \frac{\sigma^2 p}{n},$$

usando $(\Pi_{\mathbf{A}})_{ii} \geq 0$ e $\text{tr}(\Pi_{\mathbf{A}}) = \text{rank}(\mathbf{A}) \leq p$. Markov fecha. $\square$

Corolários 2 e 3

Para o Corolário 2, intersecte quatro eventos: $\mathcal{T}$ (Lema 5, probabilidade $\geq 1 - \alpha$); $\{\widehat{\sigma}_{\max}^2 \leq 2B_X^2 C_U\}$ (Lema 6), que torna a λ do enunciado admissível, isto é $\lambda \geq 2\lambda_0$; $\{\lambda_{\min}(\widehat{\Sigma}) \geq \gamma/2\}$ (Proposição 3), que com (4) dá $\widetilde{\gamma} \geq \kappa_1 C_U/2$; e $\{\|\mathbf{b}\|_n^2 \leq \mathcal{B}_J^2/\alpha'\}$, que é Markov aplicado a $\mathbb{E}\|\mathbf{b}\|_n^2 = \|f - f_J\|_{L_2(P)}^2 \leq \mathcal{B}_J^2$ (Corolário 1, primeira cota) — a identidade vale porque os $(\mathbf{X}_i, \mathbf{U}_i)$ são i.i.d. com lei P . Substituir em (ii) e (iii) do Teorema 1 dá o enunciado. A versão lenta é a mesma conta com (i) e o Lema 7.

Para o Corolário 3, dentro de cada bloco (ℓ, m) as ψ_{jk} , $j < J$, são ortonormais em $L_2[0, 1]$, logo $\|\widehat{g}_{\ell m} - \Pi_J g_{\ell m}\|_{L_2[0,1]}^2 = \sum_{jk} v_{\ell m, jk}^2$; somar sobre os pq blocos dá $\|v\|_2^2$. A segunda afirmação é $(x+y)^2 \leq 2x^2 + 2y^2$ com o Lema 1 de E1.3 em cada bloco. $\square$

6 O que foi transposto e o que é novo

- **Transposto de Bühlmann e van de Geer (2011), Seção 6.2:** a desigualdade básica; a dualidade $|\langle \boldsymbol{\varepsilon}, \widetilde{\mathbf{B}}v \rangle_n| \leq \|\widetilde{\mathbf{B}}^\top \boldsymbol{\varepsilon}/n\|_\infty \|v\|_1$; a calibração $\lambda \geq 2\lambda_0$; o argumento de cone do Passo 4; a conversão $\|v_{S_0}\|_1 \leq \sqrt{s_0}\|v\|_2$ e a constante de compatibilidade à primeira potência em predição.

- **Transposto do WALL teórico:** a organização em passos (básica, calibração, ℓ_1 do oráculo, cota a priori) do Apêndice “Slow-Rate Track”; a observação de que a calibração sub-gaussiana não sofre inflação logarítmica (Passo 3a do Lemma “LASSO prediction consistency”); a separação entre o enunciado incondicional (taxa lenta, sem esparsidade) e o condicional (taxa rápida).
- **Novo:** a perfilagem dos níveis não penalizados com (4), que substitui a condição de cone com coordenadas não penalizadas pela forma consumível de E1.4 e faz a constante não depender de S_0 ; o tratamento do viés por Young com a análise em dois casos do Passo 5, que mantém o enunciado não assintótico e válido também quando o viés domina; o termo $\sigma^2 p/n$ explícito; e o Lema 7, cuja conclusão não depende de π — é o que permite enunciar a taxa lenta em Besov geral, e não só em $B_{2,\infty}^s$ como no WALL.
- **Diferença de perda:** o WALL trabalha com a perda logística e precisa de uma etapa de localização (margem local) que a perda quadrática dispensa, porque a curvatura é constante. Em compensação, a perda quadrática com erro não limitado exige a Hipótese 2, que o WALL não precisa ($Y \in \{0, 1\}$).

7 O que isto não cobre

- **A norma populacional.** Tudo aqui é em $\|\cdot\|_n$, a norma empírica. A passagem a $\|\hat{f} - f\|_{L_2(P)}$ exige concentração uniforme sobre a classe de funções do espaço de aproximação e fica em E1.6.
- **A escolha de J_n e de λ_n .** O Corolário 2 é não assintótico e vale para qualquer J ; equilibrar $s_0 \log(pqN_J)/n$ contra $2^{-2Js'}$, e obter $n^{-2s'/(2s'+1)}$, é E1.6.
- **O regime comprimível.** Sob a Hipótese de Besov o oráculo em geral tem $s_0 = d$, e a taxa rápida como está não ajuda; o corolário de compressibilidade (weak- ℓ_τ) que troca s_0 por uma dimensão efetiva é E1.6. O que este arquivo garante sem hipótese extra é a taxa lenta (i).
- **σ desconhecido e λ aleatório.** A calibração supõe σ conhecido e λ determinístico. Validação cruzada, BIC/EBIC e o *quantile universal threshold* são E2.3; o square-root LASSO, que dispensa σ , não está coberto.
- **O $1/\alpha'$ de Markov** no termo de viés e no termo $\sigma^2 p/n$. Com a cota uniforme do Corolário 1 (que exige $s > 1/\pi$) o termo de viés vira determinístico, ao preço da taxa pior $2^{-2J(s-1/\pi)}$; uma versão com $\log(1/\alpha')$ exigiria Bernstein para $(f - f_J)^2$ e Hanson–Wright para $\|\Pi_{\mathbf{A}} \varepsilon\|_n^2$.
- **Seleção de suporte.** Nada aqui diz que $\text{supp}(\hat{\theta}) = S_0$; é E1.7, e sob a Hipótese de Besov a pergunta sequer é a certa (o WALL faz o mesmo registro).
- **A de posto deficiente.** A perfilagem supõe posto p , o que a Proposição 3 garante com probabilidade alta mas não quase certamente. Em amostra finita, se $\mathbf{A}$ degenerar o estimador continua definido e o teorema simplesmente não se aplica.
- **A base do intervalo** (boundary = “interval”), pela mesma razão de E1.4: a constante deixa de ser uma coluna isolada.
- **Heterocedasticidade e dependência.** A Hipótese 2 é condicional e uniforme, e a amostra é i.i.d.

8 Conferência numérica

check/04-oraculo.R (imprime OK; cerca de 16 s). Desenho de E1.4: Daublets com filtro 8, $J = 3$, $p = 2$ com $X_1 \equiv 1$ e $X_2 = 1/2 + \eta$, $q = 2$, $\mathbf{U}$ uniforme em $[0, 1]^2$ (logo $c_U = C_U = 1$, $\gamma = \kappa_1 c_U = 0.25$), $d = 28$, $D = 30$, erro gaussiano com $\sigma = 0.5$, $\lambda = 2\sigma\hat{\sigma}_{\max}\sqrt{2\log(2d/\alpha)/n}$ e $\alpha = 0.05$. O que saiu em 2026-09-19:

- **Armadilha de implementação, registrada para E2.1.** O `glmnet` descarta colunas de variância zero, e a coluna não penalizada $X_1 \equiv 1$ é uma delas: passada dentro de $\mathbf{Z}$ com

`penalty.factor = 0` ela sai do ajuste e $\mathbf{A}^\top r$ não zera ($\max |\mathbf{A}^\top r/n| = 6.6 \times 10^{-1}$ na primeira tentativa). As duas saídas corretas são resolver o problema residualizado (a perfilagem do Lema 4) ou deixar a constante com o intercepto do `glmnet`. As duas dão o mesmo minimizador a 1.7×10^{-8} , e a solução satisfaz as condições KKT de (1): $\max |\mathbf{A}^\top r/n| = 8.9 \times 10^{-16}$, $\max(\|\mathbf{B}^\top r/n\|_\infty - \lambda) = 2.8 \times 10^{-9}$, e igualdade com sinal no suporte ativo a 5.2×10^{-8} .

- **Lema 4(iii).** $\tilde{\gamma} \geq \lambda_{\min}(\hat{\Sigma})$ em todas as réplicas; em $n = 400$, mediana $\lambda_{\min}(\hat{\Sigma}) = 0.1411$ e mediana $\tilde{\gamma} = 0.1458$. A cadeia que o teorema consome, $\tilde{\gamma} \geq \lambda_{\min}(\hat{\Sigma}) \geq \gamma/2 = 0.125$, vale em 90% das réplicas em $n = 400$ (E1.4 já registrava que a razão $\lambda_{\min}(\hat{\Sigma})/\lambda_{\min}(\Sigma)$ é 0.40 em $n = 200$ e 0.84 em $n = 3200$).
- **Lema 6 e Observação 2.** $\hat{\sigma}_{\max}$ é 1.085, 1.042, 1.026 em $n = 200, 800, 3200$, contra a cota $B_X \sqrt{C_U} = 1.5$; em $J = 2, \dots, 6$ com $n = 4000$, $\hat{\sigma}_{\max}$ vai de 1.02 a 1.14 enquanto $\max_{i,a} |Z_{ia}|$ vai de 3.04 a 11.47.
- **Lema 5.** A cobertura de $\mathcal{T}$ é 1.000 em $n = 200$ e em $n = 1600$ sobre 400 réplicas, contra o nominal 0.95: a cota sub-gaussiana é conservadora por um fator 2 (λ_0 mediano 0.1437 contra $\|\tilde{\mathbf{B}}^\top \varepsilon/n\|_\infty$ mediano 0.0717 em $n = 200$).
- **Lema 7.** A desigualdade de Hölder por nível é saturada no pior caso ($\max = 1.0000$ sobre $\pi \in \{1, 1.5, 2, 4, \infty\}$ e $j = 2, \dots, 8$); em sequências de Besov construídas com $s = 0.3, 0.5, 1.5$, $\|\theta^*\|_1$ é 12.39, 10.80, 6.56 contra as cotas 13.87, 12.00, 7.00.
- **Taxa lenta.** $\|\tilde{\mathbf{B}}v\|_n^2 \leq 6\lambda \|\theta^*\|_1 + 4 \|\mathbf{b}\|_n^2$ em todas as réplicas, com θ^* esparsos (folga mínima 23.0 $\times$) e com θ^* densos de Besov (folga mínima 12.6 $\times$).
- **Taxa rápida, com $s_0 = 4$ e sem viés.** Nenhuma violação da cota $64\lambda^2 s_0/\tilde{\gamma}$ em 6×60 ajustes; a folga cai de 371 $\times$ em $n = 200$ a 187 $\times$ em $n = 6400$ (as constantes de Bühlmann e van de Geer são grosseiras, como se espera). O que a etapa pedia medir:

$$\frac{\|\hat{f} - f\|_n^2}{\lambda^2 s_0} = 1.566, 1.617, 1.573, 1.541, 1.548, 1.557 \quad (n = 200 \rightarrow 6400),$$

razão máxima sobre mínima 1.05 ao variar n por um fator 32; e $n \|\hat{f} - f\|_n^2$ entre 90.4 e 106.9, isto é, a taxa é $1/n$ com J fixo. As cotas de $\|v\|_1$ e $\|v\|_2^2$ do Teorema 1(ii) valem, com folga de duas ordens.

- **Observação 3.** $E \|\Pi_{\mathbf{A}} \varepsilon\|_n^2$ contra $\sigma^2 p/n$: razão 1.19, 0.93, 0.90 em $n = 200, 800, 3200$.
- **Com viés.** $g_{11} = \sin(2\pi u)$, cuja projeção em W_J com $J = 3$ deixa $\|g - \Pi_J g\|_{L_2[0,1]} = 0.0058$. A desigualdade rápida e a de predição valem em todas as réplicas, e $\|\mathbf{b}\|_n^2$ concentra no valor populacional $\|f - f_J\|_{L_2(P)}^2$ a menos de 25%, que é o passo de Markov do Corolário 2.

Referências

Referências fora de `docs/referencias-verificadas.bib` vão ao handoff.

- Bühlmann, P. e van de Geer, S. (2011). *Statistics for High-Dimensional Data*. Springer. (`buhlmann2011statistics`, verificada em L1; numeração conferida em L3.) A taxa lenta é o Corolário 6.1, “Consistency of the Lasso” (p. 104, Seção 6.2.2), e não o Teorema 6.1; o Teorema 6.1 (p. 106, mesma seção) já é a taxa rápida sob compatibilidade com $\beta^* = \beta^0$; o Teorema 6.2 (p. 111) está na Seção 6.2.3, “Linear approximation of the truth”, e é a versão com viés de aproximação, que é a transposta aqui. As coordenadas não penalizadas são tratadas na Seção 6.9, “The weighted Lasso” (pp. 139–141), não na Seção 6.2.3. O Corolário 6.8 (p. 152, Seção 6.12), usado por E1.4, é a transferência da compatibilidade da Gram populacional para a empírica.
- Klopp, O. e Pensky, M. (2015). Sparse high-dimensional varying coefficient model: nonasymptotic minimax study. *The Annals of Statistics* 43(3), 1273–1299.

(Klopp-Pensky-2015, verificada em L1.) Eq. (1.8), Lema 1 e Teorema 2 são o vizinho do caso $q = 1$ com $\mathbf{X} \perp \mathbf{U}$.

- Tropp, J. A. (2012). User-friendly tail bounds for sums of random matrices. *Foundations of Computational Mathematics* 12, 389–434. (`tropp2012user`, copiada da bibliografia do WALL e verificada em L3.) Usada por E1.4, citada aqui só pela Proposição 3.